

复杂网络下具有预测与自我调节能力的拥塞控制算法

邱泽敏, 万智萍

(中山大学 新华学院, 广州 510520)

摘 要: 现有拥塞控制算法在复杂网络环境下存在丢包率过大的问题。为此, 通过研究网络拥塞的控制问题, 提出一种具有预测与自我调节能力的拥塞控制算法。采用模糊神经网络的控制器预测网络拥塞, 根据缓冲器中的队列长度进行实时预测, 在发生拥塞前, 通过抑制控制输入端的发送速率, 并结合递增参数和递减参数等变量动态调节发送速率。实验结果表明, 该算法在不同信噪比下能够保持较好的收敛效果, 而且网络丢包率不受网络交换速率的影响, 具有较好的稳定性与保真性。

关键词: 网络拥塞; 神经网络; 队列长度; 自我调节; 预测

中文引用格式: 邱泽敏, 万智萍. 复杂网络下具有预测与自我调节能力的拥塞控制算法[J]. 计算机工程, 2017, 43(12): 115-119.

英文引用格式: QIU Zemin, WAN Zhiping. Congestion Control Algorithm with Prediction and Self-regulation Ability Under Complex Network[J]. Computer Engineering, 2017, 43(12): 115-119.

Congestion Control Algorithm with Prediction and Self-regulation Ability Under Complex Network

QIU Zemin, WAN Zhiping

(Xinhua College, Sun Yat-sen University, Guangzhou 510520, China)

[Abstract] Existing congestion control algorithm still exists the problem of packet loss rate is too large in the complex network environment. In response to this phenomenon, through studying the problem of network congestion control, this paper proposes a congestion control algorithm, which has the ability of prediction and self-regulation. It uses fuzzy neural network controllers to predict the congestion in the network. According to the queue length in buffer for real-time prediction. Before the congestion is about to occur, it uses transmission rate of the control input to suppress. It dynamically adjusts the transmission rate combined with variables like increment parameters and decrement parameters. Experimental results show that, this algorithm can be maintained better convergence effect at different signal-to-noise ratio. And its network packet loss rate is not affected by the exchange rate of the network. It has good stability and fidelity.

[Key words] network congestion; neural network; queue length; self-regulation; prediction

DOI: 10.3969/j.issn.1000-3428.2017.12.022

0 概述

随着网络技术的日益发展, 计算机网络的拥塞问题已极大地影响了用户的使用体验与数据传递。单一地提高硬件设备的投入并不能持续地防止网络的拥塞。因此, 近年来相继出现了许多拥塞的控制算法, 其中比较常见的为基于速率的拥塞控制算法。这些算法根据端点间的数据反馈进行流控制, 即控制网络的信源速率^[1]、接收速率^[2]或瓶颈节点的容量^[3-4]。但这些拥塞控制算法通常在低速交换的网络中才能发挥拥塞控制效果, 在高速交换的网络中往往会出现数据延时, 进而造成网络的动态不稳定。

而神经网络凭借其良好的自我学习与硬件兼容特点^[5-7], 使其在计算机网络性能分析、控制以及人工智能等领域进行交叉和有机结合, 以适应人们日益发展网络建模及性能分析的需要。为解决在不同交换速度下的网络中保持网络的数据传递效果, 结合神经网络与拥塞控制算法, 进而实现网络拥塞控制最大化的控制效果^[8-9]。

本文在模糊神经网络的基础上对网络的拥塞进行预测与控制, 提出一种具有自我调节能力的拥塞控制算法。根据神经网络中的队列长度对网络进行拥塞预测, 实时地反馈于信源并对其速率进行控制, 为实现网络的自适应调节, 此外, 通过网络的递增参

数和递减参数等变量动态调节发送速率。

1 拥塞分析

拥塞是网络链接失败或者线路设备发生严重过负荷后产生的正反馈现象^[10]。图 1 为网络负载与吞吐量间的关系。




图 1 网络负载与吞吐量关系

通过观察可以看到,当负载较小时,网络的吞吐量与负载间是呈正比关系的,一开始在网络负载较小的情况下,其网络吞吐量负载增加且增加的量不断加大。当网络负载到达 A 点后,网络的吞吐量虽然也随着网络负载的增加而增加,但其增加量不断变小;直到网络负载到达 B 点后,其网络吞吐量急剧下降;将 A 点附近称之为拥塞避免区,A 点后 B 点间,称之为拥塞恢复区,而 B 区之后,则称之为拥塞崩溃区。

在网络中为了最大限度地利用网络资源,如果能够网络的拥塞控制在上述的拥塞恢复区(即 A 与 B 点之间的区域),那么所获得的工作状态便可称之为理想状态。此时需要将网络控制在 B 点左边位置,否则网络会出现崩溃现象;为此,需要设置一个拥塞的控制策略,来对网络进行约束与限制。

2 神经网络的系统分析

根据模糊神经网络(Fuzzy Neural Network, FNN)的数据特点,本文对其进行分层分析,大致将网络分为 4 层^[11-12];各层分析如下所示。

1)第 1 层:输入层。该层用于接收外部的输入信号,并将其定义为输入变量,直接把输入信号传到第 2 层;输入信号的连接权为单位值。

$$net_1^1 = x_1, net_2^1 = x_2 \quad (1)$$

2)第 2 层:隶属函数计算层。该层每个节点代表一个隶属函数,充当记忆单元,与第 1 层的连接权值为 1。

$$out_{ik}^2 = \mu_{ik} = \exp \left[-\frac{(net_i^1 - \lambda_{ik})^2}{\delta_{ik}} \right] \quad (2)$$

$i = 1, 2; k = 1, 2, \dots, 7$

其中, λ_{ik} 为隶属函数的中心, δ_{ik} 为高斯隶属函数的宽度,即方差。

3)第 3 层:综合计算法层。该层将第 2 层得到的数据进行汇总,并进行整合,传输到第 4 层。

$$net_j^3 = \prod_{i=1}^2 out_{ik}^2, j = 1, 2, \dots, 49$$

$$out_j^3 = net_j^3 \quad (3)$$

4)第 4 层:推理结果输出层。该层输出最终结果。

$$net_k^4 = \sum_{j=1}^m out_j^3 w_j^c$$

$$out_k^4 = p^* = \frac{net_k^4}{\sum_{j=1}^m out_j^3}$$

其中, w_j^c 为可调权值系数, m 为模糊规则数。

为实现不断学习与优化模糊规则,对隶属函数的形状与加权系数进行如下定义。

设性能指标函数为:

$$J = \frac{1}{2} [Q_{nef}(k+1) - q(k+1)]^2 \quad (4)$$

采用最速下降法修正网络中的加权系数,即按 J 对加权系数的负梯度方向进行搜索调整。

$$w_j^c(k+1) = w_j^c(k) - \eta(k) \frac{\partial J}{\partial w_j^c} \quad (5)$$

其中, η 是学习速度。

$$\frac{\partial J}{\partial w_j^c} = \frac{\partial J}{\partial q(k)} \cdot \frac{\partial q(k)}{\partial q^*} \cdot \frac{\partial q^*}{\partial w_j^c}$$

$$= -[Q_{nef} - q(k+1)] \frac{\partial q(k)}{\partial q} \cdot \frac{out_j^3}{\sum_{j=1}^{49} out_j^3} \quad (6)$$

其中, $\partial q(k)/\partial q^*$ 用符号函数 $\text{sgn}(\partial q(k)/\partial q^*)$ 进行近似代替,而 $\lambda_{ik}, \delta_{ik}$ 则是用类似学习算法进行求取,其方法为:

$$\begin{cases} \lambda_{ik}(k+1) = \lambda_{ik}(k) - \eta(k) \frac{\partial J}{\partial \lambda_{ik}} \\ \delta_{ik}(k+1) = \delta_{ik}(k) - \eta(k) \frac{\partial J}{\partial \delta_{ik}} \end{cases} \quad (7)$$

根据以上函数进行模糊推理,能够自适应地对隶属函数的参数和加权系数进行修正,进而更好地对系统参数的变化进行响应。

3 拥塞控制策略

结合上述模糊神经网络的数据特点,本文通过利用 FNN 控制器对下一个将要到达的流进行预测^[13],并结合当前缓冲区中的队列信息,即当前队列位于 2 个阈值 λ_{\min} 和 λ_{\max} 之间时,预测网络中是否将发生拥塞。一旦预测出拥塞将要发生,即马上将预测信息反馈于源端,同时依据本文的网络拥塞控制策略进行处理。反之,不进行丢包处理。

假设结点的缓冲区大小值为 Q ,时间间隔值为 T , λ_i 为 $T_{i-1} \sim T_i$ 时刻间到达的总字节数, $T_i - T_{i-1} = T(i=1, 2, \dots, n; n \in N)$,队列的恒定服务速率为 C, q_{i+1}

为 T_{i+1} 时刻的队列长度, 则可得函数方程:

$$q_{i+1} = \min(\max(q_i + \lambda_{i+1} - C), Q) \quad (8)$$

根据式(8), 当 $\max(q_i + \lambda_{i+1} - C)$ 时, 判断缓冲区溢出, 证明包丢失现象的发生。

λ_{i+1} 可以通过 FNN 进行预测得到, q_i 可以通过网络管理信息获得; 因此, 采用式(8)得到预测值 q_{i+1} , 将队列长度 q_{i+1} 作为拥塞控制策略值, 从而判断是否发生拥塞。

4 拥塞预测

结合端点间的信息传递信息特点, 设神经网络预测表达式:

$$\hat{\gamma}_{k+1} = F[\gamma_k, \gamma_{k-1}] \quad (9)$$

其中, $\hat{\gamma}_{k+1}$ 为神经网络预测的输出, γ_k, γ_{k-1} 为神经网络预测的输入, $F[\cdot]$ 为未知的神经网络函数。

通过采用 Elman 动态递归网络, 对缓冲器中队列长度做出预测^[14-15]。神经网络的输入为过去相邻 2 个时刻队列长度值的变化量 γ_k, γ_{k-1} , 输出为下一时刻队列长度值的变化量 $\hat{\gamma}_{k+1}$ 。

使用该预测值计算下一时刻与实际值的误差平方值, 作为目标函数对神经网络进行训练, 当采样周期为 k 时, 则函数满足如下表达式:

$$\hat{\gamma}_{k+1} = \sum_{j=1}^N W_{hoj}(k) x_j(k) - T_0(k) \quad (10)$$

其中, $x_j(k) = f(\sum_{j=1}^N W_{chbj}(k) x_{cb}(k) + \sum_{i=1}^N W_{ihbj}(k) \gamma_{k+1-i} - T_{hj}(k))$, N 为隐层的单元数, $x_c(k) = x(k-1)$, 而 W_{ih}, W_{ch}, W_{ho} 为输入层至隐层、结构单元至隐层、隐层至输出层的连接权值, λ_{hj}, λ_0 分别为隐层单元和输出层单元的阈值, $f(\cdot)$ 为激活函数, $f(x) = 1/(1 + e^{-x})$ 。

目标函数 E 表达式为 $E(k) = \frac{1}{2}(\gamma_{k+1} - \hat{\gamma}_{k+1})^2$,

下面为权值与阈值的修正公式:

$$B(\alpha, \beta) = \frac{1}{T \sqrt{\frac{2Np(1-\beta)}{3}} + T_0 \min\left(1, 3 \sqrt{\frac{3Np(1-\beta)}{8}}\right) p(1 + 32p^2)}$$

而在拥塞不发生超时的情况下, 上述函数的分母将没有 T_0 部分, 即:

$$B(\alpha, \beta) = \frac{1}{T \sqrt{\frac{2Np(1-\beta)}{3}}} \quad (11)$$

已知网络的往返时间差异由瓶颈链路的队列长度确定, 数据包 P_k 的瓶颈链路 L_{neck} 的排队等待时间为 $tq_i^k - tq_{i-1}^k$, 则数据包的往返时间差:

$$T_{i+1} - T_i = t_{i+1} + \frac{q_{i+1} - (t_i + q_i)}{B_{neck}} \quad (12)$$

其中, t_{i+1} 和 t_i 表示 $i+1$ 和 i 在瓶颈链路以外的网络的延迟总和, B_{neck} 为瓶颈链路 L_{neck} 的带宽, 设:

$$\begin{aligned} W_{hoj} &= W_{hoj}(k-1) - \eta_{ho} \frac{\partial E(K)}{\partial W_{hoj}(k-1)} \\ &= W_{hoj}(k-1) + \eta_{ho} \cdot (\gamma_k - \hat{\gamma}_k) \cdot x_j(k-1) \end{aligned}$$

$$\begin{aligned} W_{ihij}(k) &= W_{ihij}(k-1) - \eta_{ih} \frac{\partial E(K)}{\partial W_{ihij}(k-1)} \\ &= W_{ihij}(k-1) + \eta_{ih} (\gamma_k - \hat{\gamma}_k) \\ &\quad \cdot W_{hoj}(k-1) \cdot f'(\sum h_j) \cdot \gamma_{k-i} \end{aligned}$$

$$\begin{aligned} W_{chij}(k) &= W_{chij}(k-1) - \eta_{ch} \frac{\partial E(K)}{\partial W_{chij}(k-1)} \\ &= W_{chij}(k-1) + \eta_{ch} (\gamma_k - \hat{\gamma}_k) \\ &\quad \cdot W_{hoj}(k-1) f'(\sum h_j) x_{ch}(k-1) \end{aligned}$$

$$\begin{aligned} \lambda_{hj}(k) &= \lambda_{hj}(k-1) - \eta_{rh} \frac{\partial E(K)}{\partial \lambda_{hj}(k-1)} \\ &= \lambda_{hj}(k-1) - \eta_{rh} \cdot (\gamma_k - \hat{\gamma}_k) \\ &\quad \cdot W_{hoj}(k-1) f'(\sum h_j) \end{aligned}$$

其中, $\sum h_j = \sum_{b=1}^N W_{chbj}(k-1) x_{cb}(k-1) + \sum_{i=1}^N W_{chij}(k-1) \gamma_{k-i} - \lambda_{hj}(k-1)$, $\eta_{ho}, \eta_{ch}, \eta_{ih}$ 与 η_{ro}, η_{rh} 分别为权值与阈值的修正速率, $f'(\cdot)$ 为 $f(\cdot)$ 的导数。

5 拥塞避免策略

当检测到网络带宽为满时, 此时拥塞窗口将进入拥塞避免阶段。采用上述函数对系统进行预测, 当认定网络发生拥塞时, 则通过控制输入端的发送速率来实现网络对拥塞现象的发生。其中结合递增参数和递减参数等变量来对发送速率进行动态调节。设:

$$B = \frac{1}{T \sqrt{\frac{2Np}{3}} + T_0 \min\left(1, 3 \sqrt{\frac{3Np}{8}}\right) p(1 + 32p^2)}$$

其中, T 为时间参数, T_0 为超时的时间值, N 为网络的数据包个数, 即可换算为:

$$\eta_i = \frac{T_{i+1} - T_i}{T_i - T_{i-1}} \quad (13)$$

如果满足式(13), 那么队列预测公式为式(14), 采用低通滤波器对于噪声进行消除。

$$q_{i+1} = (\eta_i + 1) \times q_i - \eta_i \times q_{i-1} \quad (14)$$

通过预测下一时刻的队列长度 q_{i+1} 与控制下一时刻数据的发送速率, 来获取全局最优化的数据, 从而确保全局的负载平衡。

6 仿真实验与结果分析

通过文献[16]算法与本文算法进行收敛效果与丢包率对比, 同时将各组实验中所记录的精确度采

用曲线图形式进行比较,来验证算法的可行性。其中,实验的初始条件与随机变量均在网络仿真软件中定义,仿真所得数据则是在 Matlab 2014a 中进行数据分析。图 2 为本文仿真采用的网络结构。




图 2 网络仿真结构

上述系统采用 NS2 网络软件进行系统搭建,其中带宽容量大小为 10 Mb/s,延迟为 10 ms,而链路中间的平均数据包大小为 400 Byte,缓冲区的队列长度为 200 packet,期望长度为 100 packet。

实验 1 实际与预测效果对比实验

为了检验算法的数据预测效果,本文对取样时间为 400 s 的网络段进行数据训练,通过实际数据与本文根据反馈所得的预测数据进行监控对比,取样周期为 10 ms 时数据对比如图 3 所示。




图 3 实际与预测检测数据的对比曲线

由图 3 可以看到,网络的预测数据与实际数据基本保持一致。对系统的数据进行采样,通过对比实际与预测的数据流,验证了本文算法的数据预测效果。

实验 2 网络均衡效果测试实验

为了确保实验数据的准确性,对网络的迭代次数进行定义,即定义迭代次数为 30,并对数据取均值,实验结果如图 4、图 5 所示。通过观察算法在不同信噪比下的残余误差与误码率数据的对比可以看到,本文算法相比文献[16]算法具有更低的残余误差与误码率,所得的数据曲线始终保持在文献[16]算法的下方;而且本文算法更先进行收敛,在信噪比为 11 dB 时便进入收敛状态,而文献[16]算法则需要在信噪比为 15 dB 时才能进入收敛状态。




图 4 不同信噪比下的残余误差对比




图 5 不同信噪比下的误码率对比

实验 3 丢包率对比实验

通过不断增加网络的数据交换速率,分别采用上述 2 种算法进行网络的丢包率记录,数据曲线如图 6 所示。




图 6 算法丢包率对比曲线

通过观察图 6 可以看到,在网络交换速率较小时,本文算法所测网络丢包率与文献[16]算法基本相同;但当网络交换速率达到每分钟 40 个时,与该算法的数据差距逐渐拉大。不难发现,本文算法的丢包量并非随网络速率的不断加而逐渐加大,其丢包量在速率达到每分钟 90 个时便开始减少,有效地验证了本文算法的保真效果与稳定性。

实验 4 链路使用率对比实验

为了进一步检验算法链路的使用率情况,对其进行检验,结果如图 7 所示。




图7 链路使用率对比

在相同带宽占用的情况下,即随机过程描述为:

$$x(n+1) = 0.5(n) + 10 \times 0.5 \times \xi(n)$$

其中, $\xi(n)$ 为 0~1 均匀分布的随机数。

通过观察可以看到,在相同条件下,本文算法对链路的使用率具有较好的预测与使用效果,链路的使用率情况曲线始终保持在文献[16]算法的上方,算法在链路的路径与使用情况上具有较高的稳定性与动态调节能力。

7 结束语

本文提出一种具有自我调节能力的网络拥塞控制算法。该算法通过结合神经网络中的网络队列长度与模糊神经网络对网络拥塞进行预测,采用控制网络的输入发送速率进行拥塞的控制,由递增参数和递减参数等变量对发送速率进行实时的动态调节,以实现网络的拥塞预测与控制的最大化。实验结果表明,该算法能够获得相比文献[16]算法更好的收敛效果与数据保护效果,但算法在前期数据较少的情况下依然存在拥塞预测不准确的现象,这将作为下一步的改进目标。

参考文献

- [1] WEI Chia-Hung, CHENG Ray-Guang, LIN You-Shin. Analysis of Slotted-access-based Channel Access Control Protocol for LTE-Advanced Networks [J]. Wireless Personal Communications, 2015, 85(1): 9-27.
- [2] AN Ying, LUO Xi, LIU Yao. A Congestion Control Scheme Based on Probabilistic Packet Acceptance and Drop in Delay-tolerant Networks [J]. Concurrency and Computation Practice & Experience, 2015, 27(13): 3429-3445.
- [3] KARAMI A. ACCPdn: Adaptive Congestion Control Protocol in Named Data Networking by Learning Capacities Using Optimized Time-lagged Feedforward Neural Network [J]. Journal of Network and Computer Applications, 2015, 56(1): 1-18.
- [4] GUO Chao, ZHOU Xianwei, LIN Fuhong, et al. Novel Congestion Window Control Scheme Based on Differential Game Model over Space Information Networks [J]. Journal of Computational and Theoretical Nanoscience, 2015, 12(9): 2885-2890.
- [5] LOUSSIFI H, NOURI K, BRAIEK N B. A New Efficient Hybrid Intelligent Method for Nonlinear Dynamical Systems Identification: The Wavelet Kernel Fuzzy Neural Network [J]. Communications in Nonlinear Science and Numerical Simulation, 2016, 32(10): 10-30.
- [6] 刘贺语, 孙富春. 基于正交多项式神经网络的卫星网络 QoS 路由算法 [J]. 清华大学学报(自然科学版), 2013, 53(4): 556-561.
- [7] SINGH J, BARABANOV N. Stability of Discrete Time Recurrent Neural Networks and Nonlinear Optimization Problems [J]. Official Journal of International Neural Network Society, 2016, 74(3): 58-72.
- [8] 翟东海, 李力, 靳蕃. 基于 Additive-multiplicative 模糊神经网络的 ATM 网络拥塞控制 [J]. 控制与决策, 2004, 19(6): 651-654.
- [9] 李千目, 戚涌, 许满武, 等. 基于模糊神经网络的移动组网拥塞预测 [J]. 计算机科学, 2006, 33(10): 37-40.
- [10] 陈持鑫, 周继鹏. 基于拥塞控制的无线网络最大权调度算法 [J]. 计算机工程, 2016, 42(5): 130-133.
- [11] WAI Rong-Jong, LIN Yeou-Fu, LIU Yao-Kai. Design of Adaptive Fuzzy-Neural-Network Control for a Single-stage Boost Inverter [J]. IEEE Transactions on Power Electronics, 2015, 30(12): 7282-7298.
- [12] GOODARZI R, MOKHTARZADE M, ZOEJ M. A Robust Fuzzy Neural Network Model for Soil Lead Estimation from Spectral Features [J]. Remote Sensing, 2015, 7(7): 8416-8435.
- [13] CHISCI L, PECORELLA T, FANTACCI R. Dynamic Bandwidth Allocation in GEO Satellite Networks: A Predictive Control Approach [J]. Control Engineering Practice, 2006, 14(9): 1057-1067.
- [14] 朱瑞军, 王俊伟, 胡维礼. 神经网络自校正预测拥塞控制算法研究 [J]. 系统工程与电子技术, 2004, 26(6): 792-795.
- [15] CHO H C, FADALI S M, LEE H. Adaptive Neural Queue Management for TCP Networks [J]. Computers & Electrical Engineering, 2008, 34(6): 447-469.
- [16] ZHANG Huixiang, ZHOU Hairui, CHEN Chunlei, et al. Fast Fairness Convergence Through Fair Rate Estimation in Variable-structure Congestion Control Protocol [J]. Computer Communications, 2015, 70(3): 54-67.

编辑 顾逸斐